



[반도체] [이슈점검보고서] Kimi3발AI투자심리위축

작성자 : 정현우

작성일 : 2026.07.28

[요약]

1. 이슈 개요와 핵심 쟁점

중국 AI 스타트업 문샷 AI가 오픈웨이트 모델 Kimi K3를 공개한 이후 반도체 대형주와 중국 경쟁 AI 기업 주가가 동반 조정받았다.

- 7월 16일 SOXX(-2%)에 이어 7월 17일 중국 경쟁사 즈푸 AI(-28%)와 미니맥스그룹(-16%), 7월 20일 KODEX 반도체(-6%)가 하락함.

중국의 저비용 고효율 AI의 등장으로, 사용자들은 더 많은 토큰으로 더 많은 성과를 지향하는 토큰 맥싱에서, 적은 토큰으로 효율적으로 업무를 처리하는 모델 맥싱으로 전환하고 있음.

- Kimi K3는 지능 지표 57점으로, Claude Opus 5.0(61점), GPT-5.6 Sol(59점)에 크게 뒤지지 않는 수준으로, 최상위권 수준의 놀라운 성능 도약을 보여줌. 그러나 토큰 단위 가격으로 보면 Claude Opus 5.0, Claude Sonnet 5.0 사이에 위치하여, 가장 비용 효율적인 포지션은 아님. 느린 속도와 장황한 응답의 특성을 고려하면, 캐시 미적중 시 비용은 표면 단가보다 더 클 수 있어, 실질적인 대체 영역은 반복 대량 처리 작업에 국한됨.

투자자에게는 AI 경쟁 심화와 증류를 통한 클로드 모방 논란이라는 두 쟁점이 남았다.

- 두 쟁점에 대한 직접적인 답은, 둘 다 반도체 수요를 줄이는 방향이 아니라 늘리는 방향으로 작동한다는 것이다. 근거는 계층별 모델 동시 상주 구조, 하향되지 않은 빅 4 CAPEX 계획, 오픈웨이트 모델 제공사 자신이 겪는 컴퓨팅 부족 세 가지이며, 상세 근거는 4장 결론에서 다룸.

2. 제번스의 역설을 기반으로 한 토큰 맥싱

2025년 딥시크 등장 이후 토큰 단가 하락이 총소비 증가로 이어지는 제번스의 역설이 AI 업계에서 실제 사례로 논의되기 시작했으며, Kimi K3는 이 패턴을 가격이 아닌 모델 규모 확대 경로로 재현했다.

- 딥시크는 초저가·무제한 정책으로 "토큰 맥싱" 경쟁에 불을 붙였고, 마이크로소프트 CEO 사티아 나델라는 이를 곧바로 "제번스의 역설"로 짚었음.
- Kimi K3는 가격 인하가 아니라 2.8조 파라미터·100만 토큰 컨텍스트로 모델 자체가 무거워지며 메모리 소비를 늘리는 경로로 총소비를 확대함(상세 내용은 2장 참고).

3. 토큰 맥싱에서 모델 맥싱으로의 전환

기업의 AI 비용 부담이 임계점에 도달하며 업무 난이도별로 모델을 나눠 쓰는 "모델 맥싱"이 확산되고 있으나, 모델 맥싱 시대의 병목은 GPU 연산력이 아니라 HBM의 용량과 대역폭이다.

- SDLLMTK 지수 기준 프런티어·오픈웨이트 모델 간 토큰 단가는 약 4.9 배 격차가 나지만, Kimi K3의 표면 단가 우위(47%)는 응답 상황함 때문에 실제 작업당 비용 기준으로는 9%까지 줄어듦.
- 계층별 모델을 동시에 HBM에 상주시켜야 하는 구조적 제약 때문에, 모델 맥싱은 반도체 수요를 줄이는 것이 아니라 늘리는 방향으로 작동함(상세 내용은 3장 참고, 세부 계산은 Appendix A 참고).


4. 결론

Kimi K3 발 AI 투자심리 위축은 반도체 펀더멘탈의 훼손이 아니라 수요 경로에 대한 오독에서 비롯된 조정이며, 모델 맥싱으로의 전환은 HBM 수요를 줄이는 것이 아니라 늘리는 방향으로 작동한다.

- 근거는 계층별 모델 동시 상주라는 구조적 제약, 하향되지 않은 빅 4의 CAPEX 계획, 오픈웨이트 모델 제공사 자신이 겪는 컴퓨팅 부족 세 가지임.
- 다만 이 판단은 수요의 방향에 관한 것으로, 수혜의 크기는 3분기 CAPEX 가이드선스와 SK하이닉스·삼성전자의 HBM 관련 공시로 확인해야 함(상세 내용은 4장 참고).

[구조도]

Kimi K3 충격의 본질은 AI 수요 둔화가 아니라 토큰 맥싱에서 모델 맥싱으로의 전환이다




Kimi K3발 투자심리 위축은 수요 둔화가 아니라 모델 맥싱 전환에 대한 오독이며, 결과적으로 HBM 수요 확대 논리로 귀결된다.

[목차]

1. 이슈 개요와 핵심 쟁점	6
KIMI K3 발표와 반도체 대형주·중국 AI 동종업계 동반 조정	6
문샷 AI의 사업 현황과 기업가치 급등	7
KIMI K3와 주요 프런티어 모델의 사양 비교	7
토큰 단가와 처리 속도로 본 모델별 경쟁력	8
투자자에게 발생한 핵심 쟁점 1: AI 경쟁 심화	9
투자자에게 발생한 핵심 쟁점 2: 증류 논란과 오픈소스 AI 금지 논란	10
2. 제번스의 역설을 기반으로 한 토큰 맥싱	13
제번스의 역설의 개념과 성립 조건	13
증기기관 효율화와 19세기 영국의 석탄 소비 증가	13
딥시크발 토큰 단가 하락과 AI 시대 토큰 맥싱 국면	14
딥시크와 KIMI K3의 공통점과 차이점	16
3. 토큰 맥싱에서 모델 맥싱으로의 전환	17
기업 AI 비용 부담의 임계점 도달과 모델 맥싱의 확산	17
SDLLMTK로 본 프런티어와 오픈웨이트의 단가 격차	18
KIMI K3의 표면 단가와 실사용 비용의 괴리	19
모델 맥싱 시대의 승리 조건과 모델별 적합도	21
4. 결론	24
중국 오픈웨이트 모델 부상과 반도체 수요의 실제 방향	24
증류 논란의 정책 리스크와 반도체 수요 연결 경로	24
AI 하드웨어 기업에 미치는 영향과 낙폭의 성격	25
AI 소프트웨어 기업에 미치는 영향과 컴퓨팅 제약	26
핵심 투자판단과 모니터링 포인트	26

1. 이슈 개요와 핵심 쟁점




Kimi K3 발표와 반도체 대형주·중국 AI 동종업계 동반 조정

중국 AI 스타트업 문샷 AI가 오픈웨이트 대규모언어모델 Kimi K3를 한국 기준 2026년 7월 17일, 미국 기준 2026년 7월 16일 공개한 이후, 한국 증시는 휴장을 거친 첫 거래일에 급락했고 중국 경쟁 AI 기업 주가도 동반 하락했다.

- 오픈웨이트(모델 가중치 파일을 공개해 누구나 내려받아 자체 서버에서 구동할 수 있게 하는 방식)로 공개된 Kimi K3는 미국 기준 7월 16일, 한국 기준 7월 17일 새벽에 공개됨.
- 7월 16일 SOXX(-2%)에 이어 7월 17일 중국 경쟁사 즈푸 AI(-28%)와 미니맥스그룹(-16%), 7월 20일 KODEX 반도체(-6%)가 하락함. 특이한 부분은 미국과 한국 AI 모델 기업과 인프라 기업에 대한 우려가 중국의 AI 모델과 인프라 기업의 강세로 받아들여지지 않았음. 시장은 중국 내에서도 AI 경쟁 심화를 우려하고 있음.

표1. Kimi K3 발표 전후 주가 반등(KODEX 반도체, SOXX, Z.AI, MiniMax Group)



자료: Koyfin

문샷 AI의 사업 현황과 기업가치 급등

문샷 AI는 중국 베이징에 소재한 AI 스타트업으로, Kimi 모델 시리즈 개발사이며 Kimi K3 흥행을 계기로 기업가치가 1년 만에 40억달러에서 300억달러로 뛰었다.

- 사업모델은 API 제공이며, 가격 정책은 답시크식 초저가 대신 폐쇄형 프런티어 모델 대비 저렴한 중간값을 택했음.
- 연간반복매출은 2026년 4월 2억 달러에서 6월 3억 달러로 50% 늘었고, K3 출시 후 일일 매출이 최소 6배 증가했음. 공개한 지 4일 뒤인 7월 20일, 수요 폭발과 컴퓨팅 자원 용량 부족으로 인해 신규 구독을 일시 중단했으며, 6개월 내 홍콩 증시 상장을 추진 중임.

Kimi K3와 주요 프런티어 모델의 사양 비교

Kimi K3는 총 2.8조 개, 활성 1,040억 개 파라미터의 MoE 구조 모델로, 답시크 V4 Pro 대비 50% 더 큰 용량을 요구하는 무거운 모델이다.

- MoE(전문가 혼합, 전체 모델 중 질문마다 일부 하위 모듈만 선택적으로 사용해 연산량을 줄이는 구조)는 실제 추론에 쓰는 활성 파라미터 비율을 낮춰 연산 비용을 절감함. Kimi K3는 896개 전문가 중 16개만 활성화하며, 가중치는 4비트 부동소수점 방식인 MXFP4로, 활성값은 MXFP8 정밀도로 양자화됐음.
- Claude Fable5·GPT-5.6·Grok 4.5는 파라미터 총량·활성량·레이어 수·가중치 정밀도를 공식적으로 공개하지 않아 확인하기 어려움. 그러나 답시크 대비 50% 가까이 더 무거운 모델이라는 점은 확인 가능함.

표3. Kimi K3와 주요 프런티어 모델 사양 비교

모델	개발사	파라미터(총/활성)	유형	컨텍스트 윈도우	레이어	가중치 정밀도	공개 방식
Kimi K3	문샷 AI	2.8조 / 1,040억	MoE(896개 중 16개 활성)	100만 토큰	[확인 필요]	MXFP4/MXFP8	오픈웨이트
Claude Fable5	Anthropic	[비공개]	프런티어(위험도별 이중라우팅)	100만 토큰	[비공개]	[비공개]	폐쇄형
GPT-5.6 Sol(max)	OpenAI	[비공개]	MoE(추정)	105만 토큰	[비공개]	[비공개]	폐쇄형
Grok 4.5	xAI	1.5조 / [비공개]	MoE	50만 토큰	[비공개]	[비공개]	폐쇄형
답시크 V4 Pro	답시크	1.6조 / 490억	MoE(하이브리드 어텐션)	100만 토큰	61개	FP4/FP8 혼합	오픈웨이트
Gemini 3.1 Pro Preview	구글	[비공개]	Sparse MoE	100만 토큰	[비공개]	[비공개]	폐쇄형

자료: Artificial Analysis

토큰 단가와 처리 속도로 본 모델별 경쟁력

표4. 토큰 단가·처리 속도·지연시간 비교(Artificial Analysis 기준, 모델별 최상위 설정)

모델	지능지표	처리 속도 (토큰/초)	지연시간 (초, 첫 토큰까지)	가격(달러/백만 토큰, 입력/출력)	컨텍스트 윈도우
Kimi K3 (max)	57	33.3	144.34	3.00/15.00	100만
GPT-5.6 Sol (max)	59	80.6	144.31	5.00/30.00	100만
GPT-5.5 (xhigh)	55	85.9	125.18	5.00/30.00	92.2만
Gemini 3.1 Pro Preview	46	129.5	41.27	2.00/12.00	100만
Gemini 3.6 Flash (high)	50	240.1	18.38	1.50/7.50	100만
Claude Fable5 (max)	60	73.1	197.59	10.00/50.00	100만
Claude Opus 4.6 (max)	44	41.8	17.81	5.00/25.00	100만
Claude Sonnet 4.6 (max)	47	52.2	132.90	3.00/15.00	100만
Claude Opus 5.0 (max)	61	53.5	67.72	5.00/25.00	100만
Claude Sonnet 5.0 (max)	53	70.1	155.43	2.00/10.00	100만
Grok 4.5 (high)	54	60.4	9.76	2.00/6.00	50만
딥시크 V4 Pro (max)	44[충돌, 52로도 인용]	73.2	1.51	0.44/0.87	100만

자료: Artificial Analysis

지능지표를 보면 Kimi K3(57 점)는 Claude Opus 5.0(61 점), GPT-5.6 Sol(59 점)에 크게 뒤지지 않는 수준으로, 최상위권 수준의 놀라운 성능 도약을 보여준다.[주장/해석] - Kimi K3 의 위치는 "최상위권에 근접한 모델"이라기보다, 신형 프런티어 모델이 하나씩 추가될 때마다 상대적 위치가 조금씩 밀리는 "상위권 근접이지만 격차가 유지되는 모델"로 보는 편이 더 정확함. 가격 기준으로 보면 Kimi K3(입력 3.00 달러·출력 15.00 달러)는 새로 추가된 Claude Sonnet 5.0(입력 2.00 달러·출력 10.00 달러)보다는 비싸고 Claude Opus 5.0(입력 5.00 달러·출력 25.00 달러)보다는 저렴해, 신형 Claude 두 모델의 중간 수준에 위치해있음. - 기존 10 개 모델 안에서는 Kimi K3 가 딥시크 V4 Pro 다음으로 저렴한 측에 속했으나, Claude Sonnet 5.0 이 추가되며 Kimi K3 보다 싼 폐쇄형 모델이 처음 등장함. 전체 가격 범위(딥시크 V4 Pro 0.44 달러~Claude Fable5 10 달러)에서 Kimi K3 의 상대적 위치는 여전히 낮은 편이지만, "가장 저렴한 측"이라는 설명은 더 이상 정확하지 않음.
--

Kimi K3의 지연시간(144.34 초)은 이번에 새로 추가된 Claude Opus 5.0·Claude Sonnet 5.0 까지 12 개 모델로 놓고 봐도 여전히 하위권이며, 두 신형 Claude 모델의 등장으로 "2 분 이상 vs 1 분 이내"로 뚜렷하던 기존의 두 집단 구도 자체가 흐트러졌다.[사실]

- Kimi K3(144.34 초)보다 느린 모델은 Claude Sonnet 5.0(155.43 초)·Claude Fable5(197.59 초) 둘뿐이어서, Kimi K3는 신형 모델이 추가된 뒤에도 지연시간 기준 하위 3 개 안에 그대로 남음.
- Claude Opus 5.0은 지연시간이 Kimi K3의 절반 이하(67.72 초)이면서 처리 속도도 초당 53.5 토큰으로 더 빨라, 신형 Opus가 실시간성에서 유리한 조합을 보여줌. Kimi K3(초당 33.3 토큰)는 두 신형 Claude 모델 중 어느 쪽과 비교해도 처리 속도가 뒤처짐.

Kimi K3의 "저가에 고성능"이라는 평가는 캐시 적중 조건에서만 온전히 성립하며, 느린 속도와 장황한 응답까지 함께 고려하면 실사용 비용 우위는 표면 단가보다 줄어들 수 있다.[주장/해석]

- Artificial Analysis는 Kimi K3의 지능을 4/4, 가격을 4/4로 평가했으나 이는 캐시 히트 기준이며, 속도는 1/4로 가장 낮고 장황함은 4/4로 가장 높게 평가했음. 응답이 길어질수록 캐시가 적용되지 않는 출력 토큰 과금이 늘어나 실질 비용이 표면 단가보다 커질 수 있음[데이터기관, 11].
- 실무적으로 캐시 히트 비율의 분포는 표 5와 같음. 이 때문에 지연시간에 민감한 실시간 서비스에서는 Gemini 3.1 Pro Preview·Grok 4.5처럼 속도가 빠른 모델이 유리하고, 단가가 우선인 반복 대량 처리 작업에서는 딥시크 V4 Pro·Kimi K3가 유리한 상반된 우위 구도가 형성됨.

표5. 작업 유형별 추정 캐시 히트율

구분	매 요청에서 반복되는 입력	매번 바뀌는 입력	추정 캐시 히트율
A. 거의 비반복	0~20%	80~100%	0~20%
B. 고정 지침 반복	20~50%	50~80%	20~50%
C. 긴 공통 컨텍스트 반복	50~80%	20~50%	50~80%
D. 거의 동일한 작업 반복	80~95%+	5~20%	80~95%+

자료: OpenAI·Anthropic Prompt Caching 기반 추정치

투자자에게 발생한 핵심 쟁점 1: AI 경쟁 심화

투자자에게 발생한 첫 번째 핵심 쟁점은 중국 오픈웨이트 모델이 프런티어 모델에 근접하며 격화된 AI 경쟁 심화다.

- 저비용·오픈소스의 프런티어 모델급 최상위 성능 근접과 그로 인한 생성형 AI 지출 비용 하락 우려로, AI 인프라 대규모 투자의 지속성에 의문을 제기했음. 3장에서 살펴보겠지만, 실제로 여러 기업들이 AI 비용 급증으로 인해 사용량을 제한하거나, 한도를 설정하고

있으며, 토큰 지출 인덱스는 6 월부터 하락세를 이어오고 있음. 이는 즉 AI 모델 기업의 매출액에 직접적인 타격으로 이어지기에, 그들의 투자 수익성에 대한 의문 심화로 연결됨.

- 저자의 입장은, 단기적으로는 투자 심리에 악영향임. 그러나 (1) KIMI K3 가 결코 가벼운 모델이 아니며, (2) 성능 발전은 증류를 통해 저렴하게 이루어냈지만, 컴퓨팅 비용이 저렴해진 건 아니라는 점, (3) 실제로 문샷은 컴퓨팅 자원 부족으로 인해 신규 구독을 막았다는 점, (4) 문샷 또한 출혈 경쟁으로 인해 억지로 저렴한 가격으로 제공하기에, 지속 가능한 효율화가 아니라는 점을 고려했을 때 장기적으로 보았을 때 오히려 반도체 업황을 강화하게 되는 계기라고 생각함.
- 이 쟁점이 반도체 수요 펀더멘탈에 실제로 어떤 영향을 미치는지에 대한 직접적인 답은, 계층별 모델을 동시에 HBM 에 상주시켜야 하는 구조 때문에 수요를 줄이는 것이 아니라 늘리는 방향으로 작동한다는 것임. 상세 근거는 4 장 결론에서 다룸.
- 그러나 그동안 연달아 발생한 반도체 업계의 이슈가 적립되며 투심이 너무 얼어붙은 나머지, 이는 단순한 추측성 우려 수준로 그치지 않아 당분간 지속될 전망이다.

투자자에게 발생한 핵심 쟁점 2: 증류 논란과 오픈소스 AI 금지 논란

투자자에게 발생한 두 번째 핵심 쟁점은 증류를 통한 클로드 모방 논란과, 이를 계기로 미국 정부 일각에서 검토 중인 중국산 오픈웨이트 AI 사용·유통 금지 논란이며, 이 둘은 서로 다른 층위의 별개 사안이다.

- 증류 논란은 문샷 AI 가 앤스로픽 Claude 의 출력물을 부정하게 대량 수집해 Kimi K3 를 학습시켰는지를 다루는 개별 사건의 사실관계 다툼이고, 오픈소스 AI 금지 논란은 그 사건을 계기로 중국산 오픈웨이트 모델 자체의 미국 내 사용·유통을 국가 단위로 제한할지를 다루는 정책 논쟁으로, 다루는 대상의 층위가 다름.
- 미국 산업계 다수는 이 둘을 명시적으로 분리해서 다뤄야 한다는 입장임.
엔비디아·마이크로소프트·메타·오픈 AI·구글·IBM 등 35 개 기업·기관이 2026 년 7 월 24 일 발표한 공동성명 "Open Weights and American AI Leadership"은 "불법적인 모델 탈취·저작권 침해"(증류 문제)는 표적화된 법적·상업적 규제로 다루되, 오픈웨이트 모델 자체에 대한 포괄적 규제에는 반대한다는 입장을 명시함[뉴스, 58].

증류 논란은 미국 정부·앤스로픽 측 주장과 문샷 측 부인이 맞서 있어 사실관계가 확정되지 않았다.

- 2026 년 7 월 22 일 백악관 과학기술정책국장 마이클 크라치오스는 문샷 AI 가 앤스로픽의 Claude Fable 모델을 대규모로 은밀하게 증류(더 강한 교사 모델의 출력을 약한 학생 모델에 학습시켜 성능을 모방하게 하는 기법)하여 Kimi K3 를 만들었다고 공개 주장했음. 배경으로 2026 년 2 월 앤스로픽이 자사 Claude 와의 대화 약 340 만 건이 문샷 AI 로 유출·활용된 정황을 포착했다고 밝힌 사실이 있음[뉴스, 17].
- 미 재무장관 스콧 베센트는 중국 AI 모델에서 미국 LLM 의 "워터마크"(모델 출력에 남는 고유한 언어 패턴 흔적)가 발견됐다고 증류를 통한 기술 절도 가능성을 제기했고, 도용이 확인되면 제재를 가하겠다고 밝혔음[뉴스, 62].

- 문샷은 미국 모델을 학습에 썼다는 지적을 부인했으며, Claude Fable5 공개(7 월 1 일)와 Kimi K3 공개(7 월 16 일) 사이 시차가 15 일에 그쳐 이 기간만으로 증류를 통해 해당 성능에 도달하기는 어렵다는 연구자 반론도 제기됐음[뉴스, 45][업계자료, 46].

오픈소스 AI 금지를 둘러싼 찬반은 정부 안보 라인의 신중론과, 앤스로픽을 포함한 업계 전체의 반대론으로 나뉘며, 2026 년 7 월 28 일 현재로는 반대론이 훨씬 넓고 강한 지지를 확보하고 있다.[주장/해석]

- **찬성(신중론) 측:** 월스트리트저널은 2026 년 7 월 20 일, 미국 정부 안보 담당자들이 중국 AI 기업에 대한 거래 제한과 오픈웨이트 모델 사용 금지 행정명령까지 검토했다고 보도했음. 근거는 증류를 통한 지재권 절도와, 검증되지 않은 외국 모델의 안보 위험(백도어 등)을 막아야 한다는 것임[뉴스, 59]. 베센트 재무장관의 제재·거래제한명단 경고도 이 신중론과 같은 축에 있으나, 그 발언은 증류가 확인된 기업에 대한 표적 제재를 겨누는 것이지 오픈웨이트 모델 자체의 전면 금지는 아님[뉴스, 17][뉴스, 62].
- **반대 측:** 엔비디아·마이크로소프트·메타·오픈 AI·구글·AMD·IBM 등 35 개 기업·기관이 참여한 공동성명은 오픈웨이트 모델이 미국 AI 리더십에 필수적이며 포괄적 규제 대신 표적화된 틀로 대응해야 한다고 주장함[뉴스, 58]. 엔비디아 젠슨 황은 악시오스 인터뷰에서 중국 AI 모델이 뛰어나다며 미국 기업의 중국 오픈웨이트 모델 사용을 허용해야 한다고 밝혔고, 증류에 대해서도 다른 지능으로부터 배우는 것은 지능의 본질적 과정이라며 실제 불법 행위에만 책임을 물어야 한다고 선을 그었음[뉴스, 60]. AMD 리사 수도 오픈소스를 뛰어난 기술로 평가하며 과도한 규제가 오히려 기업들을 중국산 대안으로 내몰 수 있다고 경고했음[뉴스, 61].
- **이 사건의 피해 당사자인 앤스로픽 CEO 다리오 아모데이조차 국가·공개여부 기준의 전면 금지에는 반대함.** 그는 위험한 능력이 없는 오픈웨이트 모델을 공공재로 규정하며, 국내 사용을 금지해도 악의적 행위자는 규제를 따르지 않아 핵심 안보 위험은 해결되지 않는다고 지적했음. 대신 공개 여부가 아니라 실제 위험 능력을 기준으로 규제를 차등화하고, 첨단 반도체 수출 통제와 산업적 규모의 증류 통제가 오픈웨이트 공개 자체보다 더 근본적인 위협이라고 주장했음[뉴스, 59].
- **우위 판단:** 증류 피해를 주장한 당사자인 앤스로픽까지 포함해 미국 빅테크 전체가 국가 단위 전면 금지에 반대하고 있고, 정부 측 금지론은 아직 검토 단계에 머물러 실제 행정조치로 이어지지 않은 반면(7 월 28 일 현재 확인된 지정·금지 사례 없음), 표적 규제론은 경쟁사를 포함한 업계 전체의 합의에 가까움. 현재 시점에서는 반대론(표적 규제론)이 명확히 우위에 있다고 판단하되, 이는 여론·업계 입장의 우위일 뿐 실제 정책 결정은 아직 유동적임.

오픈웨이트가 곧 "무료 AI"는 아니며, 이 구분이 반도체 수요 판단에 중요하다.

- 젠슨 황은 무료 AI 가 하드웨어에 좋은 일이라며 중국 오픈소스 AI 금지에 반대했으나, 여기서 "무료"는 모델 가중치를 누구나 내려받을 수 있다는 뜻이지 실제 구동 비용이 없다는 뜻은 아님[뉴스, 60].
- 실제로 Kimi K3 는 오픈웨이트로 공개됐음에도 문샷이 API 이용료로 100 만 토큰당 입력 3.00 달러·출력 15.00 달러를 부과하고 있고(위 표 4 참고), 자체 구동에는 약 1.5TB 의

메모리와 슈퍼노드급 설비가 필요함(2~3 장 참고). 오픈웨이트는 라이선스 비용과 API 종속을 없애고 자체 호스팅 선택지를 넓힐 뿐, 연산·메모리 비용까지 없애지는 않음.

- 따라서 "무료 AI 가 칩 수요를 늘린다"는 주장은 가격이 0 이 된다는 뜻이 아니라, 접근 장벽이 낮아진 만큼 더 많은 주체가 AI 를 채택해 총수요가 늘어난다는 뜻으로 읽는 것이 정확하며, 이는 이 보고서 2~3 장의 결론(총소비 증가·HBM 수요 확대)과 같은 방향임.

모델 맥싱으로의 전환은 반도체 수요를 줄이는 변화가 아니라 계층별 모델을 동시에 상주시켜야 하는 구조를 통해 HBM 수요를 늘리는 변화이며, 이번 낙폭은 이 경로를 잘못 읽은 데서 비롯된 조정으로 판단한다. 다만, 반도체 종목의 조정은 AI 데이터센터 투자의 지속성에 대한 의문으로부터 비롯되었으며, 이번 이슈는 해당 의문에 대한 근거 중 하나일 뿐이다.

- 또한 수혜의 크기는 3 분기 하이퍼스케일러 CAPEX 가이드스와 국내 메모리 대형주의 HBM 관련 공시로 확인해야 한다. 자세한 근거는 4 장 결론 참고.

2. 제번스의 역설을 기반으로 한 토큰 맥싱



제번스의 역설의 개념과 성립 조건

제번스의 역설은 효율화로 값싸진 자원을 더 많이 쓰려는 수요 확대 폭이, 단위당 절감된 소비분보다 커지는 현상을 가리킨다.

- 자원 이용 효율이 개선되면 그 자원을 쓰는 단위당 비용이 낮아짐. 낮아진 비용은 그 자원을 더 저렴하고 매력적인 선택지로 만들어 수요 자체를 확대시킴[학술자료, 19].
- 이는 리바운드 효과로도 불리며, 100%를 넘어 총소비 자체가 늘어나는 경우만을 좁은 의미의 제번스의 역설로 구분함[학술자료, 19].

증기기관 효율화와 19세기 영국의 석탄 소비 증가

제번스의 역설은 1865년 영국 경제학자 윌리엄 스탠리 제번스가 저서 《석탄 문제》에서, 증기기관의 연료 효율이 개선됐음에도 영국의 석탄 총소비량이 오히려 급증한 현상을 지적하며 처음 제시한 개념이다.

- 제번스는 1776년 제임스 와트가 개량한 증기기관이 이전 세대보다 훨씬 적은 석탄으로 동일한 동력을 냈고, 이 때문에 석탄을 쓰는 비용 자체가 낮아지며 증기기관이 산업 전반에 훨씬 더 널리 보급됐다고 분석함[학술자료, 20].
- 그 결과 영국의 석탄 소비량은 19세기 말까지 3배로 늘었음. 효율 개선이 기계 1대당 석탄 소비는 줄였지만, 기계 보급 대수가 그보다 훨씬 빠르게 늘어나며 총소비량을 밀어올린 것으로 해석됨[학술자료, 20].

- 20 세기 이후에는 건물 단열 성능이나 자동차 연비가 개선돼도 총 에너지 소비가 실제로 줄어드는지에 대한 논쟁으로 이어졌음. 자동차 연비가 좋아지면 운행 비용이 낮아져 오히려 주행거리가 늘어나는 사례가 대표적으로 인용됨[학술자료, 20].

딥시크발 토큰 단가 하락과 AI 시대 토큰 맥싱 국면

딥시크는 2024 년 12 월 26 일 V3 를, 2025 년 1 월 20 일 R1 을 오픈웨이트로 공개했고, 시장이 실제로 반응해 반도체 대형주가 급락한 시점은 그로부터 일주일 뒤인 2025 년 1 월 27 일(월, 미국 정규장)이었다. 저렴한 학습 비용과 가격, 우수한 성능을 지닌 고효율 AI 의 등장은 AI 업계에서 제번스의 역설이 실제 사례로 처음 논의되는 계기가 됐다.

- 딥시크는 신규 모델 R1 의 GPU 사용량 기준 학습비용이 약 558 만달러에 그친다고 공개했음. 오픈 AI 등이 신규 모델 하나를 학습시키는 데 통상 5 억에서 10 억달러를 쓰는 것으로 알려진 점과 비교하면 약 90 배에서 180 배 낮은 수준임[증권사 레포트, 21][증권사 레포트, 22].
- API 가격에서도 같은 격차가 확인됨. 딥시크 R1 의 출시 시점 가격은 100 만 토큰당 입력 0.55 달러·출력 2.19 달러로, 비교 대상인 오픈 AI o1 의 출력 60 달러 대비 약 27 분의 1 수준임. 대신증권 또한 당시 "오픈 AI 가격의 3%에서 5% 수준"이라고 평가한 것과도 대체로 일치함[증권사 레포트, 22].
- 나델라는 반응 당일인 2025 년 1 월 27 일 자신의 소셜미디어 계정에 제번스의 역설을 설명한 자료를 링크하며, AI 가 더 효율화되고 대중화될수록 그 사용량은 오히려 폭발적으로 늘어날 것이라는 취지로 반응했음[뉴스, 23].

딥시크는 사용량 제한을 두지 않는 파격적 가격 정책으로 토큰 소비 경쟁에 불을 붙였고, 이 경쟁적 소비 확대 구도는 이후 업계에서 "토큰 맥싱"이라는 이름으로 명문화됐다.

- 다수의 폐쇄형 모델이 유료 버전에서도 사용량 제한을 두던 것과 달리, 딥시크는 사용량을 무제한으로 열어 공개 직후 주요 앱스토어 1 위에 올랐음. 국내 증권가에서도 이런 가격 경쟁이 다른 모델 제공사로 확산될 공산이 크다는 평가가 당시 나왔음[증권사 레포트, 21].
- "토큰 맥싱"이라는 표현 자체는 2026 년 3 월 엔비디아 CEO 젠슨 황이 "연봉 50 만달러를 받는 엔지니어가 그중 20 만달러를 토큰 구매에 쓰지 않는다면 우려스러운 일"이라고 발언하며 실리콘밸리에 유행한 신조어로, 토큰 사용량 자체를 성과 지표로 삼아 최대한 많이 소비하려는 문화를 가리킴[뉴스, 24].

토큰 단가 하락이 총소비 증가로 이어진다는 논리는 국내 증권가에서도 인정되며, 코인베이스의 실사용 사례와 2030 년 토큰 소비량 전망이 이를 뒷받침한다.

- 유안타증권은 경량화 모델과 희소 전문가 혼합 구조, 캐시 최적화로 동일 서비스에 필요한 컴퓨트가 점진적으로 줄어드는 추세를 인정하면서도, 효율화에 따른 수요 감소 효과보다 AI 활용 범위 확대에 따른 총수요 증가 효과가 더 우세하다고 평가함[증권사 레포트, 25].


2026 년 7 월 등장한 Kimi K3 역시 출시 3 일 만에 문샷 자체 GPU 가 용량 한계에 도달해 신규 구독을 중단한 사례를 남기며, 효율화가 곧 총 컴퓨팅 수요 감소로 이어지지 않는다는 딥시크 시대의 패턴을 그대로 재현했다.[주장/해석]

- 문샷은 2026년 7월 19일 공식 계정을 통해 지난 48시간 동안 수요가 급증해 GPU가 용량 한계에 가깝게 몰렸다고 신규 가입을 일시 중단한다고 밝혔음. 대규모언어모델 하나의 인기만으로 자체 인프라가 이틀 만에 한계에 도달한 것임[뉴스, 27].
- Kimi K3는 전체 896개 전문가 모듈 중 태스크당 16개만 선택적으로 활성화해 개별 연산량 자체는 줄이도록 설계됐음에도, 정작 총수요 급증이 인프라 한계를 앞당긴 것으로 해석됨[뉴스, 27][뉴스, 10].
- 저비용·효율화 모델의 등장도 곧바로 컴퓨팅 수요 감소로 이어진다는 단순한 우려에는 반하는 근거임.

다만 Kimi K3가 반도체 수요를 늘리는 경로는 딥시크와 다르다. 딥시크는 가격 하락이 총사용량을 증가해 메모리 소비량을 늘리는 경로였던 반면, Kimi K3는 딥시크 대비 모델 자체의 무게가 무거워지며 메모리 소비량을 직접적으로도 늘리는 경로에 가깝다.

- 블룸버그는 Kimi K3의 2조 8000억개 파라미터와 100만 토큰 컨텍스트 창이 이전 세대보다 훨씬 더 많은 메모리 용량을 요구한다고 평가함. 저정밀도로 압축해도 약 1.4테라바이트의 메모리와 엔비디아 차세대 시스템급 AI 랙이 필요하다고 분석함[뉴스, 28].
- 딥시크는 가격이 싸지니 더 쓰는 경로로 총소비를 늘렸다면, Kimi K3는 모델이 무거워지니 더 많은 메모리가 필요해지는 규모 경로로 총소비를 늘린다는 점에서 제번스의 역설이 작동하는 메커니즘 자체가 다름. 세부 비교는 다음 절에서 다룸.

사진1. 딥시크 R1 공개 후 KODEX 반도체와 SOXX 주가 추이



자료: Koyfin

딥시크와 Kimi K3의 공통점과 차이점

표1. 딥시크와 Kimi K3 비교

항목	딥시크(V3/R1, 2024.12~2025.01)	Kimi K3(2026.07)
공개일	2024/12/26(V3), 2025/01/20(R1)	2026/07/16(미국시간)
공개 방식	오픈웨이트	오픈웨이트
파라미터	총 1.6조(V4 Pro 기준), 활성 490억	총 2.8조, 전문가 896개 중 16개 활성화
아키텍처	MoE(384개 라우팅 전문가+공유전문가 1개)	MoE(Stable LatentMoE, 896개 전문가 중 16개 활성화)
가격 정책 (100만 토큰당)	입력 0.55달러, 출력 2.19달러	입력 3.00달러, 출력 15.00달러
컴퓨팅 제재 관련 성격	미국 GPU 수출규제 하 저비용 개발 주장	"미국 컴퓨팅 제재를 우회한 사상 최대 오픈웨이트 모델" 평가
미국 반도체 반응		
한국 반도체 반응		
반등 여부	실적 시즌 통과 후 반등(6개월 뒤 필반지수 +29%)	[확인 필요, 관찰 기간 부족]
반도체 수요 시사점	저비용 개발·추론이 CAPEX 축소 우려 촉발	메모리 수요 확대 근거로 재해석

자료: 신한투자증권(2025-01-31), 대신증권(2025-01-30), CNBC·Forbes·Bloomberg(2025-01-27~29), 뉴스1(2025-01-27), 매일신문·서울경제·네이트(2026-07-19), 헤럴드경제(2026-07-20, 블룸버그 인용), Tom's Hardware(2026-07-17)


두 모델의 공통점은 오픈웨이트 공개 방식과 MoE 구조에 있으며, 이 두 특징이 겹치면서 시장은 두 사건을 유사한 "쇼크"로 프레이밍했다.

- 오픈웨이트 방식은 제 3 자가 가중치를 직접 받아 독립적으로 성능을 검증할 수 있게 해, 폐쇄형 모델의 자체 발표보다 "기술격차가 좁혀졌다"는 인식을 시장에서 더 쉽게 확산시킴. 딥시크와 Kimi K3 모두 이 경로로 미국과의 기술격차 축소 인식을 증폭시켰다는 평가를 받음[뉴스, 29].
- 두 모델 모두 MoE 구조를 채택해 전체 파라미터 중 일부만 선택적으로 활성화하는 방식으로 개별 연산 비용을 낮췄음. 다만 모델 전체를 GPU 메모리에 상시 적재해야 하는 구조 자체는 동일해 메모리 수요를 줄이지는 못함[뉴스, 27].

결국 두 사건 모두 제번스의 역설이 예측하는 방향인 총소비 증가로 귀결되고 있으나, 총소비가 늘어나는 경로는 가격 하락 중심에서 모델 규모 확대 중심으로 옮겨가고 있다.[주장/해석]

- 이 경로 전환이 어떤 배경에서 일어나고 있으며, 이것이 "모델 맥싱"이라는 다음 국면으로 어떻게 이어지는지는 다음 장에서 다룸.

3. 토큰 맥싱에서 모델 맥싱으로의 전환



기업 AI 비용 부담의 임계점 도달과 모델 맥싱의 확산

모델 맥싱은 업무 난이도에 따라 서로 다른 등급의 모델을 나눠 배정하는 운영 방식으로, 최신 최고 사양 모델 하나에 모든 작업을 몰아주던 토큰 맥싱을 대체하며 확산되고 있다.

- 상위 20% 수준의 핵심 업무에만 최상위 모델을 투입하고 나머지 단순 작업은 구형 모델이나 오픈웨이트 모델에 배정하는 것이 기본 형태임[업계자료, 33].
- 배경에는 기업들이 뒤처질 수 없다는 압박에 최신 모델을 무분별하게 도입한 뒤 청구서를 받아들이고 비용 최적화에 나선 흐름이 있음[업계자료, 33].

기업들의 절감 노력은 사용 한도 부과, 저비용 모델 사용 의무화, 성과 지표 변경까지 조직 운영 규칙 자체를 바꾸는 단계에 들어섰다.

- 2026년 4월 우버는, 연간 AI 예산을 4개월 만에 소진한 뒤 직원 1인당 월 1,500달러 한도를 도입했고, 6월 월마트는 단순 작업에 저비용 모델 사용을 의무화했음[업계자료, 32].
- 6월 아마존은 직원별 AI 사용량 순위 공개를 중단했음. 사용량 자체가 성과로 인식돼 불필요한 과사용을 부추킨다는 판단이었음[업계자료, 32].
- 6월 삼성전자는 토큰 소비량 대비 절감된 노동시간 비율로 팀 성과를 평가하는 방식으로 지표를 바꿨고, 7월 세일즈포스는 실제로 문제를 해결했을 때만 과금하는 결과 기반 요금제를 내놔음[업계자료, 32].
- 7월 마이크로소프트는 장문 대화에서 반복되는 맥락을 요약해 재사용하는 메모리 프레임워크로 컨텍스트 토큰을 98% 줄일 수 있다고 주장했다[업계자료, 32]. [사실 검증 필요]

모델 맥싱은 개념 단계를 넘어 실제 서비스 운영에 적용되고 있으며, 코인베이스 최고경영자는 향후 1년 반 안에 전체 AI 작업의 80%가 지금보다 99% 저렴한 모델로 대체될 것으로 전망했다.[주장/해석]

- 6월 말 코인베이스는 중국산 오픈웨이트 모델로 라우팅해 AI 비용을 절반 가까이 절감했다고 밝혔음[뉴스, 26].
- 7월 퍼플렉시티는 일반적인 작업에 즈푸 AI의 GLM-5.2를 쓰고 복잡한 작업에서만 최상위 모델을 호출하는 방식으로 운영 효율을 높이고 있음[증권사 레포트, 35].

SDLLMTK로 본 프런티어와 오픈웨이트의 단가 격차

SDLLMTK는 실리콘데이터가 발표하는 일일 지수로, 여러 경로에서 관측된 LLM 추론 토큰 거래가를 정규화해 100만 토큰당 달러로 환산한 값이다.

- 프런티어 API 제공사, 오픈웨이트 추론 플랫폼, 브로커 전용 인스턴스 시장, 자체 호스팅 참조 배포 등 성격이 다른 출처의 관측값을 함께 수집함[데이터기관, 34].
- 입출력 토큰 혼합비, 컨텍스트 윈도우, 배칭 동작, 신뢰성 기준으로 정규화한 뒤 통계적 이상치를 제거해 매일 발행함[데이터기관, 34].
- 추적 모델 400개 이상, 일일 바스켓 20개 이상, 가격·거래량 출처 20개 이상을 반영해 글로벌 LLM 추론 지출의 90% 이상을 포괄한다고 밝히고 있음[데이터기관, 34].
- 국내에서도 유진투자증권이 2026년 1월부터 7월까지의 토큰 지출 지수 추이를 GPU 렌탈가와 나란히 주간 관찰 지표로 게재하고 있어, 이 지수가 국내 리서치에서도 참조 지표로 쓰이기 시작했음을 보여줌[증권사 레포트, 36].


이 지수의 강점은 리스트 가격이 아닌 실제 서빙 비용을 추적한다는 점이고, 약점은 정규화 가중치와 바스켓 구성이 공개되지 않아 제3자가 재현할 수 없다는 점이다.[주장/해석]

- 리스트 가격은 할인·캐시 조건·프로모션을 반영하지 못하는 반면 이 지수는 실제 거래 관측값을 쓰므로, GPU 렌탈 지수와 병행하면 인프라 원가가 토큰 가격으로 전이되는 경로를 추적할 수 있음[데이터기관, 34].
- 반대로 입출력 혼합비나 배칭 조건을 어떻게 가중했는지가 공개되지 않았고 커버리지 90% 이상이라는 수치도 산출사 자체 주장이라, 절대 수준을 그대로 인용하기보다 추세 방향을 읽는 데 쓰는 것이 안전함[데이터기관, 34].
- 일일 바스켓이 20개 이상이라는 표현은 구성 종목이 바뀔 여지를 남기므로, 시점 간 비교 시 구성 변경 효과가 섞였을 가능성을 감안해야 함.

2026년 4월 22일 기준 프런티어 세그먼트는 100만 토큰당 4.20달러, 오픈웨이트 세그먼트는 0.85달러로 약 4.9배 격차가 났으며, 이 격차의 크기가 곧 모델 맥싱의 경제적 유인이다.[사실]

- 전체 작업의 80%를 오픈웨이트로 옮기면 혼합 단가는 100만 토큰당 1.52달러로 내려가 기존 대비 64% 절감됨. 코인베이스 최고경영자가 말한 80% 대체 전망이 겨냥하는 절감 폭이 이 수준임[데이터기관, 34][업계자료, 33].

표1. 토큰 지출 인덱스 추이(2026년 1월~7월)



자료: Bloomberg, 유진투자증권(2026-07-21)[증권사 레포트, 36]

이 지수는 SDLLMTK(SiliconData LLM Token Expenditure Index)와 별개로 유진투자증권이 자체 집계해 게재하는 블렌디드 토큰 지출 지수이며, 프런티어·오픈웨이트를 나누지 않은 전체 시장 평균값이라 SDLLMTK의 세그먼트별 수치(표 위 문단 참고)와 직접 비교할 수는 없다.[사실]

- 2026년 1월 1.2~1.3 달러 수준에서 출발해 2월 한때 1.8 달러 부근까지 튀어 올랐다가 3월 1.3 달러 아래로 재차 내려앉았고, 이후 완만히 우상향해 5~6월 2.0~2.1 달러 구간에서 고점을 형성한 뒤 7월 들어 1.6 달러 안팎으로 되돌림.
- Kimi K3 발표 시점은 이 지수가 고점을 지나 이미 하락 전환한 이후에 해당해, Kimi K3 발표 자체가 이 지수의 추세를 새로 만든 것은 아님. 토큰 지출이 꺾인 상황에서 추가적으로 기업의 AI 비용 절감 수단이 생겼다는 점에서 단기적으로 악영향임.

Kimi K3의 표면 단가와 실사용 비용의 괴리

Kimi K3는 프런티어급 지능지표를 프런티어 대비 낮은 표면 단가에 제시하면서, 최고사양 모델에 토큰을 무제한 투입할 이유가 있는지에 대한 의구심을 키워 모델 맥싱 전환을 가속했다.[주장/해석]

- 지능지표 57점으로 Claude Fable5의 60점, GPT-5.6 Sol의 59점에 이어 3위이면서, 캐시·입력·출력을 7대2대1로 혼합한 블렌디드 단가는 100만 토큰당 2.31달러로 GPT-5.6 Sol의 4.35달러 대비 47% 저렴함[증권사 레포트, 37].

- 같은 지능 계층에서 절반 수준 가격이 제시되면 최상위 모델의 희소성 프리미엄이 약해지고, 폐쇄형 프런티어 모델의 가격결정력에 대한 재평가로 이어짐[증권사 레포트, 39].
- 다만 아래에서 확인하듯 이 표면 단가 우위는 실제 업무 단위로 환산하면 대부분 소멸하며, Kimi K3가 촉발한 것은 저가 고성능의 실현이라기보다 저가 고성능이 가능하다는 인식임.

표면 단가 47% 우위는 실제 작업 하나를 끝내는 비용 기준으로는 9%까지 줄어들며, 격차를 지우는 원인은 응답의 장황함이다.[사실]

- 삼성증권이 산출한 작업당 비용은 Kimi K3 0.95 달러, GPT-5.6 Sol 1.04 달러로 차이가 9%에 그침. 같은 기준에서 Claude Fable5는 2.75 달러, Grok 4.5는 0.31 달러, 딥시크 V4 Pro는 0.04 달러임[증권사 레포트, 37].
- 원인은 출력 토큰 사용량임. Kimi K3는 지능지표 평가에서 1억 3,000만 토큰을 생성해 중앙값 9,900만 토큰의 약 1.3배를 썼고, 출력 토큰은 캐시 할인이 적용되지 않아 단가 우위를 그대로 상쇄함[데이터기관, 11].
- 전작 Kimi K2.6 대비로도 입력 단가는 3.2배, 출력 단가는 3.8배 올랐음. 중국 모델이라고 해서 성능을 올리면서 비용을 낮출 수 있는 것은 아니라는 점을 같은 개발사 안에서 보여준 사례임[증권사 레포트, 38].

지능지표 1점당 작업 비용으로 환산하면 Kimi K3는 하위권이며, 이는 모델 맥싱의 하위 계층에서 선택받기 어려운 위치를 뜻한다.[주장/해석]

- Grok 4.5는 지능지표 54점을 0.31달러에, 딥시크 V4 Pro는 44점을 0.04달러에 제공해 단위 비용당 성능이 Kimi K3의 각각 2.9배, 18.3배임[증권사 레포트, 37].
- 모델 맥싱에서 물량의 대부분을 차지하는 것은 단순 작업 계층이며, 이 계층의 선택 기준은 절대 성능이 아니라 단위 비용당 성능임. Kimi K3의 강점인 절대 지능은 이 계층에서 값을 인정받지 못함.
- 반대로 최상위 계층에서는 절대 지능이 기준이 되는데, 여기서는 60점과 59점을 확보한 두 프런티어 모델이 앞섬.

속도까지 함께 보면 지연시간에 민감한 실시간 서비스에서 Kimi K3를 선택할 근거는 더 좁아진다.[사실]

- 출력 속도는 초당 33.3 토큰으로 Artificial Analysis 추적 98개 모델 중 59위이며, 중앙값 초당 67 토큰의 절반 수준임[데이터기관, 11].
- 응답 길이가 1.3배 긴 점까지 겹치면 같은 작업을 끝내는 데 걸리는 시간은 초당 129.5 토큰을 내는 Gemini 3.1 Pro Preview 대비 4배 이상 벌어짐[데이터기관, 11].
- 삼성증권도 가격과 속도와 성능을 함께 고려하면 기존 최상위 모델에서 전환할 유인이 낮다는 견해가 있다고 정리했음[증권사 레포트, 37].

표2. 표면 단가와 실사용 비용의 비교

모델	지능지표	블렌디드 단가 (달러/100만 토큰)	작업당 비용 (달러)	지능지표 대비 작업당 비용
Claude Fable5	60	7.70	2.75	21.8

GPT-5.6 Sol	59	4.35	1.04	56.7
Kimi K3	57	2.31	0.95	60.0
Opus 4.8	56	3.85	1.80	31.1
Grok 4.5	54	1.35	0.31	174.2
딥시크 V4 Pro	44	0.18	0.04	1,100.0

자료: 삼성증권(2026-07-20), Artificial Analysis(2026-07-28 확인)[증권사 레포트, 37][데이터기관, 11]

모델 맥싱 시대의 승리 조건과 모델별 적합도

모델 맥싱은 하나의 승자를 고르는 게임이 아니라 계층마다 다른 승자를 두는 게임이며, 계층별 선택 기준은 절대 지능, 단위 비용당 성능, 응답 속도로 갈린다.[주장/해석] - 상위 계층은 실패 비용이 큰 소수 작업을 다루므로 절대 지능이 기준이고, 물량이 적어 단가가 총비용에 미치는 영향이 제한적임. - 하위 계층은 물량이 대부분을 차지하므로 단위 비용당 성능이 기준이며, 여기서 절감되는 금액이 모델 맥싱의 실제 효과를 결정함. - 중간 계층은 사용자가 응답을 기다리는 실시간 작업이 몰려 있어 속도가 기준이 되며, 초당 토큰 수와 응답 길이가 함께 반영됨.
--

표3. 사양 기준 비교(1장 표3 재인용)

모델	파라미터(총/활성)	유형	컨텍스트 윈도우	가중치 정밀도	공개 방식
Kimi K3	2.8조 / 1,040억	MoE(896개 중 16개 활성)	100만 토큰	MXFP4/MXFP8	오픈웨이트
Claude Fable5	[비공개]	프런티어(위험도 별 이중 라우팅)	100만 토큰	[비공개]	폐쇄형
GPT-5.6 Sol(max)	[비공개]	MoE(추정)	약 105만 토큰	[비공개]	폐쇄형
Grok 4.5	1.5조 / [비공개]	MoE	50만 토큰	[비공개]	폐쇄형
딥시크 V4 Pro	1.6조 / 490억	MoE(하이브리드 어텐션)	100만 토큰[충돌]	FP4/FP8 혼합	오픈웨이트
Gemini 3.1 Pro Preview	[비공개]	Sparse MoE	100만 토큰	[비공개]	폐쇄형

자료: Artificial Analysis 모델별 페이지(2026-07-28 확인), 1장 표3 재인용[데이터기관, 11]

표4. 단가·속도·지능 기준 비교(1장 표4 재인용, 작업당 비용 추가)

모델	입력 단가(달러 /100만)	출력 단가(달러 /100만)	처리 속도(토큰/초)	지능지표	작업당 비용(달러)
Kimi K3	3.00(캐시 0.30)	15.00	33.3	57	0.95
Claude Fable5	10.00	50.00	72.1	60	2.75
GPT-5.6 Sol(max)	5.00	30.00	[확인 필요]	59	1.04

Grok 4.5	2.00(캐시 0.50)	6.00	85.6	54	0.31
딥시크 V4 Pro	0.44	0.87	71.4	44	0.04
Gemini 3.1 Pro Preview	2.00	12.00	129.5	46	[확인 필요]

자료: Artificial Analysis 모델별 페이지(2026-07-28 확인), 삼성증권(2026-07-20), 1장 표4 재인용[데이터기관, 11][증권사 레포트, 37]

표 3 과 표 4 를 병목 기준으로 다시 읽으면 Kimi K3 는 세 계층 어디에서도 1 순위가 되기 어려우며, 우위 지대는 초장문 맥락을 다루는 지연 둔감 배치 작업에 한정된다.[주장/해석]

- 상위 계층에서는 지능지표 57 점으로 60 점과 59 점에 밀림. 작업당 비용이 Claude Fable5 의 3 분의 1 이라는 강점이 있으나, 이 계층은 수요 비중이 낮아 단가 우위가 총비용에 미치는 영향이 작음.
- 하위 계층에서는 작업당 비용 0.95 달러가 딥시크 V4 Pro 의 24 배, Grok 4.5 의 3.1 배임. 단위 비용당 성능이 각각 18.3 분의 1, 2.9 분의 1 이라 물량 배정 대상이 되기 어려움.
- 중간 계층에서는 Gemini 3.1 Pro Preview 가 지능지표(46 점)가 Kimi K3(57 점)보다 낮지만, 속도(129.5 토큰/초)는 3 배 이상 빠르고 표면 단가도 낮음. 절대 지능이 아니라 속도.단가가 기준인 이 계층에서는 그 격차가 오히려 Kimi K3 에 불리하게 작용함.
- 남는 영역은 100 만 토큰 컨텍스트를 한 번에 처리해야 하고 응답 지연이 문제되지 않는 대량 문서 반복 처리형 작업임. 이 조건에서는 캐시 히트가 높아 입력 단가가 0.30 달러까지 내려가고, 느린 속도가 제약으로 작용하지 않음[데이터기관, 11].

병목 관점에서 모델 맥싱 시대에 가장 유리한 조건을 갖춘 것은 특정 모델이 아니라 계층별 모델을 동시에 상주시킬 수 있는 인프라 보유 주체다.[주장/해석]


- 표 4 의 모델 중 오픈웨이트로 공개된 Kimi K3 와 딥시크 V4 Pro 는 누구나 내려받을 수 있으나, 실제 구동에는 슈퍼노드급 설비가 필요해 접근 가능한 주체가 인프라 보유 사업자로 좁혀짐[증권사 레포트, 36][증권사 레포트, 39].
- 딥시크 V4 Pro 는 KV 캐시를 전작의 10 분의 1 수준으로 낮춘 구조 덕분에 같은 HBM 용량에서 더 많은 동시 요청을 받을 수 있어, 하위 계층 대량 물량을 소화하는 데 구조적으로 유리함[증권사 레포트, 40].
- 반면 Kimi K3 는 가중치만으로 1.5TB 를 점유해 상주 비용 자체가 커, 하위 계층 전용으로 상주시키기에는 단위 물량당 인프라 부담이 큼[증권사 레포트, 37].
- 메리츠증권이 정리했듯 공개형 모델이 진보할수록 해자는 모델 기업이 아니라 인프라 확보 기업으로 이전되며, 모델 맥싱은 이 이전을 가속하는 방향으로 작동함[증권사 레포트, 39].

결과적으로 모델 맥싱 전환은 토큰 단가 하락을 통해 반도체 수요를 줄이는 경로가 아니라, 상주 모델 수 증가와 KV 캐시 부담 확대를 통해 HBM 수요를 늘리는 경로로 작동한다.[주장/해석]

- 상위 계층 최상위 모델의 가격결정력은 실제로 약해지며, 이는 폐쇄형 프런티어 모델 기업의 수익성에 직접적 위협임[증권사 레포트, 39].

- 그러나 그 물량이 사라지는 것이 아니라 여러 모델로 분산되고, 분산된 모델은 각각 HBM에 상주해야 하므로 하드웨어 총수요는 오히려 늘어나는 방향임.
- 삼성증권이 Kimi K3를 메모리를 덜 쓰는 모델이 아니라 못 쓰던 능력을 쓸 수 있게 만든 모델로 규정한 것도 같은 판단임[증권사 레포트, 37].
- 이 판단이 반도체 밸류체인 각 구간과 투자 결론으로 어떻게 연결되는지는 4장에서 다룸.

4. 결론



중국 오픈웨이트 모델 부상과 반도체 수요의 실제 방향

1장에서 제기한 첫 번째 쟁점인 AI 경쟁 심화는 반도체 수요를 줄이는 방향이 아니라 늘리는 방향으로 작동하며, 중국 오픈웨이트 모델의 부상을 곧바로 반도체 수요 감소로 읽는 시장의 초기 도식은 이번 사안에 성립하지 않는다.[주장/해석]

- 국내 증권사 네 곳의 진단도 같은 방향임. 메리츠증권은 AI 하드웨어 밸류체인 전반의 투자 위축이라는 해석을 기우로 규정했고, 유진투자증권은 낮은 서비스 가격이 낮은 추론 인프라 부담을 뜻하지 않는다고 정리했으며, 하나증권은 역대 최대 파라미터라는 표현을 역대급으로 GPU와 HBM을 쓰는 모델이라는 뜻으로 해석했고, 삼성증권은 Kimi K3를 메모리를 덜 쓰는 모델이 아니라 못 쓰던 능력을 쓸 수 있게 만든 모델로 규정함[증권사 레포트, 39][증권사 레포트, 36][증권사 레포트, 38][증권사 레포트, 37].

단기적으로 메모리에 큰 영향을 미치지 않는다고 판단하며, 장기적으로도 펀더멘탈을 강화하는 방향으로 작용할 것이라 생각함. 그럼에도 불구하고 그동안 메모리 업계에 대한 거듭된 이슈로 인해 추가에는 단기적으로 악영향으로 작용함.

증류 논란의 정책 리스크와 반도체 수요 연결 경로

두 번째 쟁점인 증류 논란은 사실관계가 아직 확정되지 않았으며, 투자 관점의 핵심은 논란 자체가 아니라 이것이 실제 제재로 옮겨갈 경우 중국에 대한 미국의 정책 불확실성이 커질 수 있다. [주장/해석]

- Claude Fable5 는 2026 년 7 월 1 일, Kimi K3 는 7 월 16 일 공개돼 두 시점의 간격이 15 일에 그침. 이 기간에 증류만으로 보고된 성능에 도달하기는 어렵다는 연구자 반론이 제기됐고, 문샷도 미국 모델을 학습에 썼다는 지적을 부인했음[업계자료, 46][뉴스, 45].
- 미 재무장관의 거래제한명단 경고는 2026 년 7 월 22 일 발언 단계에 머물러 있으며, 7 월 28 일 현재 문샷에 대한 실제 지정은 확인되지 않음[뉴스, 45].
- 미국 정부는 문샷이 태국을 경유해 수출이 금지된 엔비디아 칩에 접근했다는 의혹도 함께 제기함. 이 의혹이 사실이라면 중국 최상위 모델조차 미국산 가속기 없이는 성립하지 않는다는 뜻이어서, 오픈웨이트 모델의 부상이 오히려 미국 하드웨어 수요 증가로 이어지는 근거가 됨[뉴스, 45].

제재가 현실화되면 반도체 수요에는 상충하는 두 힘이 동시에 작용하므로, 이 리스크를 단일 방향으로 해석하지 않는 것이 타당하다.

- 중국 AI 기업의 가속기 조달 경로가 좁아지면 중국발 하드웨어 수요는 줄어듦. 다만 대중 수출 규제가 이미 작동 중이어서 추가로 줄어드는 몫 자체는 제한적일 여지가 있음.
- 반대로 미국 프런티어 기업의 지식재산이 보호되면 성능 경쟁과 그에 따른 인프라 투자는 오히려 가속됨. 삼성증권이 Kimi K3 의 등장을 미국 AI 랩의 위기감을 자극해 더 강도 높은 투자를 부르는 요인으로 본 것과 같은 맥락임[증권사 레포트, 37].

AI 하드웨어 기업에 미치는 영향과 낙폭의 성격

AI 하드웨어 기업에 대한 이번 조정은 확정된 펀더멘탈 훼손이 아니라 수요 경로를 잘못 읽은 데서 비롯된 과잉 반응에 가깝다.[주장/해석]

- 훼손을 확정하려면 하이퍼스케일러 CAPEX 축소가 확인돼야 하나, 빅 4 의 CAPEX 규모는 2025 년 약 4,100 억달러에서 2026 년 7,000 억달러 안팎으로 늘어난 계획이 유지되고 있으며 7 월 28 일 현재까지 하향 조정 근거는 확인되지 않음. 집계 기관에 따라 6,950 억달러에서 7,250 억달러로 폭이 있음[업계자료, 43].
- 하나증권은 7 월 필라델피아반도체지수의 변동성 확대를 4 월부터 과하게 쏘였던 수급이 해소되는 과정으로 진단하고, Kimi K3 의 등장이 실적 훼손 근거로는 약하다고 평가함[증권사 레포트, 38].

2025 년 1 월 딥시크 쇼크의 전개 과정이 이번 사안을 읽는 가장 직접적인 유사 사례다.

- 딥시크 공개 직후인 2025 년 1 월 27 일 필라델피아반도체지수는 하루 9% 하락해, 통계적으로 극히 이례적인 낙폭을 기록했음[증권사 레포트, 21].
- 그러나 사흘 뒤 실적을 발표한 마이크로소프트와 메타는 CAPEX 를 줄이기는커녕 각각 800 억달러와 600 억~650 억달러를 제시하며 투자 지속을 확인했음. 마이크로소프트는 전년 대비 44% 증액이었고, 메타의 2024 년 집행액은 372 억달러였음[증권사 레포트, 42]. 이후 관세 이슈가 해소된 즉시 상승 랠리를 시작했음.
- 삼성증권은 본 이슈를 중국이 하드웨어 효율을 끌어올리고 미국 기업이 이를 흡수해 서비스로 배포하는 공생 구조로 정리하면서, 딥시크 모멘트가 반복되는 패턴이 될 것으로 봄[증권사 레포트, 37].

AI 소프트웨어 기업에 미치는 영향과 컴퓨팅 제약

오픈웨이트 모델 제공사 자신이 컴퓨팅 부족에 묶여 있다는 사실은 오픈웨이트 확산을 하드웨어 수요 감소로 읽는 도식의 가장 직접적인 반증이다.[사실]

- 문샷은 Kimi K3 공개 사흘 만인 2026년 7월 19일, 48시간 동안 수요가 급증해 자체 GPU가 용량 한계에 몰렸으며 신규 가입을 일시 중단했음[뉴스, 27].
- 딥시크는 100억위안 이상 규모의 2차 투자 라운드를 진행하던 중 투자자 모집을 돌연 중단했음. 창업자 량원핑이 비공개 간담회에서 컴퓨팅 자원 부족으로 중국의 AI 기술 발전이 잠시 멈춰선 상태라고 말한 내용이 유출된 것이 계기였음[뉴스, 44].
- 두 사례 모두 중국 AI 기업의 병목이 모델 설계가 아니라 가속기 확보에 있음을 보여줌. 모델 성능이 올라갈수록 이 병목은 완화되지 않고 오히려 심해짐.

미국 프런티어 모델 기업에는 실질적 위협이 존재하나, 그 경로는 물량 이탈보다 가격결정력 약화에 가깝다.[주장/해석]

- 3장에서 확인한 대로 같은 지능 계층에서 절반 수준 가격이 제시되면 최상위 모델의 희소성 프리미엄이 약해짐. 메리츠증권도 미국 프런티어 기업의 가격결정력 약화와 점유율 이탈 우려를 인정함[증권사 레포트, 39].
- 다만 Kimi K3의 작업당 비용 우위는 GPT-5.6 SoI 대비 9%에 그치고 출력 속도는 98개 모델 중 59위여서, 최상위 계층을 당장 대체할 조건은 아직 갖추지 못했음[데이터기관, 11].
- 상위 계층에서 밀려난 물량도 사라지지 않고 여러 모델로 분산되므로, 소프트웨어 계층의 손실이 하드웨어 계층의 손실로 그대로 이어지지 않음.

종류 논란이 소프트웨어 기업에 갖는 함의는 지식재산 보호 실패가 곧 투자 회수 구조의 훼손으로 이어진다는 점이다.

- 앤스로픽은 2026년 2월 자사 모델과의 대화 약 340만 건이 문샷으로 유출·활용된 정황을 포착했다고 밝힘. 이 주장이 사실이라면 대규모 학습 투자를 들인 프런티어 성능이 훨씬 낮은 비용으로 복제될 수 있다는 뜻임[뉴스, 45].
- 미국 정부가 이례적으로 특정 중국 연구소를 공개 지목하고 재무장관이 거래제한명단을 언급한 것도, 이 회수 구조를 정책으로 방어하려는 성격으로 읽힘[뉴스, 45].
- 따라서 이 사안은 개별 기업 간 분쟁이 아니라 프런티어 모델 사업모델의 존속 조건에 관한 문제이며, 정책 대응의 강도가 미국 소프트웨어 기업의 수익성 전망을 좌우할 변수임.

핵심 투자판단과 모니터링 포인트

Kimi K3 발 AI 투자심리 위축은 반도체 펀더멘탈의 훼손이 아니라 수요 경로에 대한 오독에서 비롯된 조정이며, 모델 맥싱으로의 전환은 HBM 수요를 줄이는 것이 아니라 늘리는 방향으로 작동한다.[주장/해석]

- 근거는 세 가지임. 계층별 모델을 동시에 상주시켜야 하는 구조적 제약, 하향 조정되지 않은 빅 4 의 CAPEX 계획, 그리고 오픈웨이트 모델 제공사 자신이 겪는 컴퓨팅 부족임[자체산출, 47][업계자료, 43][뉴스, 44][뉴스, 27].

표1. 모니터링 포인트

지표	확인 시점	판단 전환 조건
빅4 하이퍼스케일러 CAPEX 가이드 스	2026년 2분기 실적 시즌	하향 시 펀더멘탈 훼손으로 전환
SK하이닉스·삼성전자 HBM 관련 공 시·IR	미정	수주·매출 부진 시 수혜 크기 하향
문샷 AI 거래제한명단 지정 여부	미정	지정 시 정책 리스크 현실화

자료: 본 보고서 종합

각주

- [뉴스, 1] 매일신문·서울경제·네이트(2026-07-19)
- [뉴스, 2] 서울신문(2026-07-17)
- [뉴스, 3] 머니투데이(2026-07-20)
- [뉴스, 4] 한국경제(2026-07-19)
- [뉴스, 5] 블록미디어(2026-07-17/19)
- [뉴스, 6] 이투데이(2026-07-20)
- [뉴스, 7] 매일신문(2026-07-19)
- [뉴스, 8] 시장 지표 교차검증 자료(2026-07-20 확인)
- [뉴스, 9] 연합뉴스(Yna, 2026-07-18)
- [뉴스, 10] Tom's Hardware(2026-07-17)
- [데이터기관, 11] Artificial Analysis, Kimi K3 모델 페이지(<https://artificialanalysis.ai/models/kimi-k3>, 2026-07-28 확인)
- [데이터기관, 12] Artificial Analysis, Claude Fable 5 모델 페이지(<https://artificialanalysis.ai/models/claude-fable-5>, 2026-07-28 확인)
- [데이터기관, 13] Artificial Analysis·OpenRouter, GPT-5.6 Sol 모델 페이지(2026-07-28 확인)
- [데이터기관, 14] Artificial Analysis·eese AI, Grok 4.5 벤치마크·가격 자료(2026-07-28 확인)
- [공식자료, 15] DeepSeek 공식 블로그·Hugging Face·Artificial Analysis, DeepSeek V4 Pro 자료(2026-07-28 확인)
- [업계자료, 16] eese AI·developersdigest.tech, Gemini 3.5 Pro 상태·Gemini 3.1 Pro Preview 가격 자료(2026-07-28 확인)
- [뉴스, 17] Cryptopolitan·The News(파키스탄)·WION 등 교차보도(2026-07-22 발생, 2026-07-28 확인)
- [데이터기관, 18] Hugging Face(unsloth/Kimi-K3, embedl 블로그 등), Kimi K3 아키텍처 상세 자료(2026-07-28 확인)
- [학술자료, 19] 위키피디아 "Jevons paradox"·"Rebound effect" 항목(2026-07-28 확인)
- [학술자료, 20] 윌리엄 스탠리 제번스, 《The Coal Question》(1865); 위키피디아 "The Coal Question"·"Jevons paradox" 항목(2026-07-28 확인)
- [증권사 레포트, 21] 신한투자증권 글로벌주식전략 "딥시크 이후 기술주 투자전략의 재구성"(2025-01-31)
- [증권사 레포트, 22] 대신증권 해외주식 Issue Comment "딥시크 발표의 의미와 영향"(2025-01-30)
- [뉴스, 23] Fortune(2025-01-27), GeekWire(2025-01-27), 사티아 나델라 소셜미디어 반응 보도
- [뉴스, 24] 젠슨 황 발언(2026-03) 인용 블로그·매체 종합(2026-07 확인)
- [증권사 레포트, 25] 유안타증권·키움증권 등 반도체 리서치 노트 종합(2026-07-20 확인)
- [뉴스, 26] 더밀크(2026-07-20)
- [뉴스, 27] Pandaily·Kimi 공식 계정·Yahoo Finance·SCMP·TechNode(2026-07-19~20)
- [뉴스, 28] 헤럴드경제(2026-07-20, 블룸버그 인용)
- [뉴스, 29] 블록미디어(2026-07-19), UC버클리 교수 평가 인용 매체(2026-07-18)
- [뉴스, 30] 더밀크(2026-07-20), 한국경제(2026-07-19), OpenRouter·Layer3labs·Analyticsvidhya(2026년 7월 기준)
- [뉴스, 31] 매일신문·서울경제·네이트(2026-07-19), CNBC·Forbes·Bloomberg(2025-01-27~29)

[업계자료, 32] economy.ac, "AI 비용 최적화 트렌드"(2026-07-22 게재, 2026-07-28 확인)

[업계자료, 33] finance-scope, "토큰맥싱에서 모델맥싱으로의 전환"(2026-07-06 게재, 2026-07-28 확인)

[데이터기관, 34] SiliconData, LLM Token Expenditure Index 제품 페이지 (<https://www.silicondata.com/products/silicon-index/llm-token-expenditure-index>, 2026-07-28 확인)

[증권사 레포트, 35] 미래에셋증권 China Weekly Issue, "'KIMI K3'로 재확인한 중국 AI의 가성비 경쟁력"(2026-07-20)

[증권사 레포트, 36] 유진투자증권 Weekly 글로벌 테크(2026-07-21)

[증권사 레포트, 37] 삼성증권 Sector Update, "Kimi Moment: 격화되는 프론티어 레이스"(2026-07-20)

[증권사 레포트, 38] 하나증권 미국 이슈 코멘트, "Kimi K3와 코어워브 이슈, 과한 해석이다"(2026-07-20)

[증권사 레포트, 39] 메리츠증권 전략 Direct Message(2026-07-19)

[증권사 레포트, 40] KB증권 중국 Tech(2026-04-27)

[공식자료, 41] NVIDIA, GB200 NVL72 공식 사양(2026-07-28 확인)

[증권사 레포트, 42] 한화투자증권 투자전략, "딥시크 패닉 금지"(2025-01-31)

[업계자료, 43] Futurum-CNBC-valueaddvc 등 하이퍼스케일러 2026년 CAPEX 집계 자료(2026-07-28 확인)

[뉴스, 44] 매일경제(2026-07-26), 딥시크 투자 유치 중단 보도

[뉴스, 45] TechCrunch-CNN-WION-Cryptopolitan 등 교차보도(2026-07-22~23 발생, 2026-07-28 확인)

[업계자료, 46] Memeburn, Kimi K3 증류 의혹의 시차 분석(2026-07-28 확인)

[자체산출, 47] Appendix A(랙 한 대 기준 병목 계산) 참고. 삼성증권(2026-07-20) 파라미터·양자화 수치와 NVIDIA GB200 NVL72(2026-07-28 확인) 공식 사양을 결합해 산출

[데이터기관, 48] Artificial Analysis, Claude Opus 4.6(max) 모델 페이지 (<https://artificialanalysis.ai/models/claude-opus-4-6-adaptive>, 2026-07-28 확인, 지원 종료·Opus 4.7(max)로 대체 명시)

[데이터기관, 49] Artificial Analysis, Claude Sonnet 4.6(max, adaptive reasoning) 모델 페이지 (<https://artificialanalysis.ai/models/claude-sonnet-4-6-adaptive>, 2026-07-28 확인)

[데이터기관, 50] Artificial Analysis, Gemini 3.6 Flash(high) 모델 페이지 (<https://artificialanalysis.ai/models/gemini-3-6-flash>, 2026-07-28 확인)

[데이터기관, 51] Artificial Analysis, GPT-5.5(xhigh) 모델 페이지(<https://artificialanalysis.ai/models/gpt-5-5>, 2026-07-28 확인, 지원 종료·GPT-5.6 Sol로 대체 명시)

[데이터기관, 52] Artificial Analysis, Gemini 3.1 Pro Preview 모델 페이지 (<https://artificialanalysis.ai/models/gemini-3-1-pro-preview>, 2026-07-28 확인)

[데이터기관, 53] Artificial Analysis, Claude Opus 5.0(max, adaptive reasoning) 모델 페이지 (<https://artificialanalysis.ai/models/claude-opus-5>, 2026-07-28 확인)

[데이터기관, 54] Artificial Analysis, Claude Sonnet 5.0(max, adaptive reasoning) 모델 페이지 (<https://artificialanalysis.ai/models/claude-sonnet-5>, 2026-07-28 확인)

[뉴스, 55] 아주경제(2026-07-26), 엔비디아·마이크로소프트·메타 등 25개사 오픈웨이트 모델 규제 반대 공동 성명 보도

[뉴스, 56] 다음뉴스 종합보도(2026-07-23), 베선트 재무장관 발언 및 중국 오픈소스 AI 제재 논란 배경, 젠스황 반박 발언 종합 정리

[뉴스, 57] 스타트업레시피(2026-07-24 관련 보도), 마이크로소프트 "Open Weights and American AI Leadership" 성명 보도

[뉴스, 58] AI타임스(2026-07-24), 엔비디아·마이크로소프트·메타·오픈AI·구글·IBM 등 35개 기업·기관 오픈웨이트 지지 공동성명 보도(나델라·올트만·황 발언 인용)

[뉴스, 59] 디지털데일리(2026-07-28), 다리오 아모데이 앤스로픽 CEO의 능력 기반 AI 규제 제안 보도(WSJ 2026-07-20 보도 인용 포함)

[뉴스, 60] AI타임스(2026-07-22~23), 젠슨 황 엔비디아 CEO 악시오스(Axios) 인터뷰 발언 보도("무료 AI는 하드웨어에 좋은 일" 등)

[뉴스, 61] 포천코리아(2026-07-23~24), 리사 수 AMD CEO AI 어드밴싱 컨퍼런스 발언 보도

[뉴스, 62] 뉴스핌·헤럴드경제·한국일보 교차보도(2026-07-21~22), 베선트 재무장관의 중국 AI 모델 워터마크·증류 의혹 제기 보도(연합뉴스 원문은 접근 차단되어 교차보도로 대체 — 이전 세션에서도 반복 확인된 접근 제한, `data/raw/news/260728a\_pm\_websearch\_토큰맥싱에서모델맥싱전환\_SDLLMTK.md` 참고)